

机器学习第四章实验内容

一、实验内容

4.1 决策树处理分类任务——肿瘤分类

（数据无需预处理，读取即可使用）

1. 使用 `sklearn.tree.DecisionTreeClassifier` 完成肿瘤分类
2. 计算最大深度为 10 时，十折交叉验证的精度(accuracy)，查准率(precision)，查全率(recall)，F1 值
3. 绘制最大深度从 1 到 10 的决策树十折交叉验证精度的变化图
4. 选做：通过调整参数，得到一个泛化能力最好的模型

4.2 实现决策树——解决贷款分类问题

使用 Lending Club Safe Loans 数据集：

1. 实现信息增益、信息增益率、基尼指数三种划分标准
2. 使用给定的训练集完成三种决策树的训练过程
3. 计算三种决策树在最大深度为 6 时在测试集上的精度，查准率，查全率， F1 值

二、数据介绍

1) LendingClub Safe Loans 数据集

文件名：

1. 原始数据： `lending-club-data.csv`
2. 字段说明： 无

数据来源： <https://www.coursera.org/learn/ml-classification>

读取方式：

```
import pandas as pd
loans = pd.read_csv('data/lendingclub/lending-club-data.csv', low_memory=False)
```

2) breast cancer 乳腺癌数据集

文件名： `Breast_Cancer_Wisconsin/data.csv`

原始数据： `Breast_Cancer_Wisconsin/data.csv`

数据用于将肿瘤分类为恶性（癌性）或良性（非癌性）

数据来源： <https://www.kaggle.com/datasets/yasserh/breast-cancer-dataset?datasetId=1829286>

数据预处理步骤：

无需数据预处理，可直接使用。